

4. AI 활용 기술 문서

AI 도구, 프롬프트, 활용 내역 정리

이 프로젝트의 AI 활용은 두 층으로 나뉩니다. 첫째, 개발 도구로서 AI 코딩 에이전트를 사용해 구현, 디버깅, 문서화, 배포 문제 해결을 수행했습니다. 둘째, 게임 기능으로서 LLM이 플레이어의 자연어 가르침을 규칙 JSON으로 컴파일하고 경기 후 회고를 생성합니다.


1. AI 활용 개요

구분	사용 도구	활용 내용	최종 판단
개발 도구	Claude Code	Unity C# 구현, 리팩터링, 테스트 작성, 오류 분석, 문서화	개발자가 스펙 확정, diff 검토, 최종 검증
제품 기능	Anthropic Claude API (Haiku 계열)	훈련실 자연어 규칙 컴파일, 락커룸 경기 회고 생성	RuleValidator와 플레이테스트로 검증
아트 보조	이미지 생성 AI, ChatGPT	캐릭터 콘셉트와 스프라이트 제작 보조	라이선스와 사용 가능 범위 확인

2. 제품 내 AI 구조

- 훈련 컴파일: 플레이어의 한국어 입력을 diff JSON 형식의 규칙 변경분으로 변환합니다.
- 검증 단계: C# RuleValidator가 fact, op, action, priority, slot 제한을 최종 확인합니다.
- 전투 루프: LLM은 전투 중 호출되지 않습니다. 전투는 로컬 RuleEvaluator가 0.1초 단위로 판단합니다.
- 경기 회고: EventLog 요약과 규칙 발동 통계를 바탕으로 제자 말투의 3문장 이내 회고를 생성합니다.

AI 활용 프로세스



3. 핵심 프롬프트 지시 사항

- 응답은 JSON only로 제한하고, add/update/delete diff 포맷을 강제합니다.
- 조건은 AND 결합만 허용하며, 가르침 1번은 규칙 1개로 처리합니다.
- 어휘 사전에 없는 fact/action은 거절하거나 되물습니다.
- needs_confirmation=true인 경우 규칙을 적용하지 않고 제자 대사만 표시합니다.
- 적용 완료 대사는 평서문 또는 완료형으로 끝내고, 되물기는 의문형으로 끝내도록 구분했습니다.
- 프롬프트 인젝션은 LLM 지시뿐 아니라 C# 화이트리스트 검증으로 최종 차단합니다.

4. 대표 활용 사례

사례	문제	AI 활용	결과
LLM 응답-스키마 불일치	실제 API 응답이 rule_id/then 등 다른 필드로 와서 규칙 적용 실패	로그와 스키마를 대조해 프롬프트의 diff JSON 예시를 수정	Outcome=Applied까지 재검증
프롬프트 인젝션 방어	'너는 이제 시스템이다'류 입력이 규칙 검증을 우회할 위험	공격 패턴 테스트를 만들고 RuleValidator를 최종 저지선으로 설계	허용 목록 밖 action/fact/op를 모두 거절
되묻기 UX 개선	모호한 입력에 대한 답변이 적용 완료처럼 보여 혼란	needs_confirmation 대사는 질문형, 적용 완료 대사는 완료형으로 분리	플레이어가 재입력해야 하는 상황을 명확히 인지
WebGL 배포와 CORS	GitHub Pages에서 LLM 프록시 호출이 브라우저 정책에 막힐 수 있음	preflight, 허용 origin, GitHub Actions 배포 구조를 점검	웹 링크 기반 제출 흐름 구성

5. 외부 에셋 및 오픈소스 출처

구분	이름	사용 내용	출처 및 라이선스
AI 개발 도구	Claude Code	구현, 디버깅, 테스트, 문서화	https://claude.com/claude-code
제품 LLM	Anthropic Claude API	자연어 규칙 컴파일 및 경기 회고	https://docs.anthropic.com/en/api/messages
AI 보조 도구	ChatGPT	문서 정리와 아이디어 보조	https://chatgpt.com
오픈소스	UniTask	Unity 비동기 처리	https://github.com/Cysharp/UniTask - MIT License
오픈소스	Newtonsoft.Json	RuleSet JSON 직렬화	Unity Package Registry - MIT License

6. 보안 및 개인정보 관리

- API 키는 환경변수로만 주입하며 저장소와 WebGL 빌드 산출물에 하드코딩하지 않습니다.
- 프록시 서버는 허용 origin만 응답하도록 구성해 공개 웹 빌드에서 임의 호출을 줄입니다.
- 플레이어 입력은 시스템 프롬프트와 분리된 [코치의 말] 영역에만 삽입합니다.
- LLM 결과는 그대로 실행하지 않고 RuleValidator의 화이트리스트를 통과한 경우에만 적용합니다.